

Mood Echo 서비스 기획 및 개발 회의

회의 정보

일시: 2024년 8월 1일

장소: 유비온 디지털 교육센터

참석자: 서규현, 정우성, 강경진, 김대운, 정혜주

작성자: 김대운, 정혜주

1. 배경

- 산업 재해의 정의 및 증가 추세
 - 산업 재해란 직장 내에서 발생하는 사고로 인해 근로자가 부상을 입거나 사망하는 것을 의미.
 - 고용노동부 통계에 따르면 2020-2021년 사이 산업 재해 발생 건수가 증가.
- 인적 요소와 산업 재해
 - 산업 재해의 주요 원인은 인적 요소이며, 정신건강 문제(특히 우울증)가 중요한 역할을 함.
 - 코로나19로 인해 '코로나 블루' 현상이 발생, 이는 우울증 증가로 이어졌고, 결과적으로 산업 재해가 늘어났다는 가설이 제기됨.
- 결정 사항
 - 배경 자료로 고용노동부 통계 데이터와 코로나19로 인한 우울증 증가 현상을 포함하기로 함.

2. 문제

- 우울증과 산업 재해의 상관관계
 - 마빈의 인간 행동 이론 및 산업안전보건학 5요소를 통해 우울증과 산업 재해 간의 관계를 설명.
 - 통계 자료를 통해 우울증 진단자 수와 산업 재해 발생률 간의 상관관계를 분석.
- 현재의 문제점
 - 현재 EAP(직원 지원 프로그램)와 PHQ-9(우울증 선별검사) 활용이 부족하여 우울증으로 인한 산업 재해를 예방하지 못하고 있음.

- 결정 사항

- 우울증과 산업 재해의 상관관계를 설명하기 위해 관련 통계 자료와 이론적 배경을 포함하기로 함.

- EAP와 PHQ-9의 현재 활용 부족 문제를 강조하기로 함.

3. 솔루션

- 서비스 소개

- Mood Echo 서비스는 음성 인식을 통해 우울증을 조기에 발견하고 지원하는 솔루션임.

- 주요 기능으로는 음성 데이터 수집, 전처리, 모델 학습 및 예측이 포함됨.

- 시스템 아키텍처

- Wav2vec2.0 모델을 사용하여 한국어 음성 데이터를 Fine-tuning한 Wav2vec-large-xlsr-korean 모델을 채택.

- 시스템 구성도 및 기술적 설명 포함.

- 서비스 활용 방안

- EAP와 PHQ-9 보강을 통해 사내 복지 차원에서 활용.

- 혼자서 얘기하는 녹음 수집 및 분석을 통해 개인의 우울증 상태를 모니터링.

- 결정 사항

- 서비스 개요, 시스템 아키텍처, 활용 방안을 구체적으로 설명하는 슬라이드를 준비하기로 함.

- 서비스 활용 예시로 피그마 화면을 준비하기로 함.

4. 기대 효과

- EAP 강화

- TAM, SAM, SOM 분석을 통해 노릴 수 있는 금액 산출.

- 우울증 조기 진단을 통해 산업 재해 예방 가능.

- 경제적 및 시간적 절약

- 대규모 설문 조사나 인터뷰보다 효율적으로 우울증을 진단할 수 있음.

- 우울증 진단을 비공개로 진행하여 낙인효과를 예방할 수 있음.

- 결정 사항

- TAM, SAM, SOM 분석 결과를 포함하여 경제적 기대 효과를 구체적으로 설명하기로 함.
- 우울증 조기 진단의 다양한 효과를 강조하기로 함.

5. 로드맵

- 단계별 로드맵
 - 초기 타겟팅: 제조, 건축 산업.
 - 서비스 확장: 대중으로의 서비스 확장.
 - 사후 케어 시스템으로 발전.
- 우울증 진단 서비스 발전
 - 멘탈케어 헬스 시스템 구축.
 - AI 상담사 시스템을 통한 지속적인 정신건강 체크.

K-Fold 교차 검증 결과

- 데이터셋별 모델 성능 해석

Base-960h 데이터셋

- Logistic Regression: 평균 정확도 68.77%
- Gradient Boosting: 평균 정확도 69.51%
- SVM: 평균 정확도 69.36%
- XGB: 평균 정확도 69.82%

해석: XGB 모델이 이 데이터셋에서 가장 높은 평균 정확도를 보였다. Gradient Boosting과 SVM도 유사한 성능을 보였다. Logistic Regression은 상대적으로 낮은 성능을 보였다.

Korean 데이터셋

- Logistic Regression: 평균 정확도 65.53%
- Gradient Boosting: 평균 정확도 69.49%
- SVM: 평균 정확도 69.36%
- XGB: 평균 정확도 69.61%

해석: 이 데이터셋에서도 XGB 모델이 가장 높은 평균 정확도를 보였다. Gradient Boosting과 SVM 모델도 비슷한 성능을 보였다. Logistic Regression은 다른 모델들에 비해 성능이 낮았다.

Base 데이터셋

- Logistic Regression: 평균 정확도 69.18%
- Gradient Boosting: 평균 정확도 69.69%
- SVM: 평균 정확도 69.36%
- XGB: 평균 정확도 69.57%

해석: Gradient Boosting 모델이 가장 높은 평균 정확도를 보였다. XGB와 SVM도 비슷한 성능을 보였다. Logistic Regression은 다른 모델들과 큰 차이는 없지만 가장 낮은 성능을 보였다.

English 데이터셋

- Logistic Regression: 평균 정확도 67.81%
- Gradient Boosting: 평균 정확도 69.67%
- SVM: 평균 정확도 69.36%
- XGB: 평균 정확도 69.61%

해석: Gradient Boosting 모델이 가장 높은 평균 정확도를 보였다. XGB와 SVM도 유사한 성능을 보였다. Logistic Regression은 상대적으로 낮은 성능을 보였다.

종합 해석

- 가장 높은 평균 정확도를 가진 Dataset/Model 조합: base-960h 데이터셋과 XGB 모델 조합이 가장 높은 평균 정확도인 69.82%를 보였다.

- Korean 데이터셋에서 가장 높은 정확도를 가진 모델: XGB 모델이 69.61%로 가장 높은 평균 정확도를 보였다.

대부분의 데이터셋에서 XGB와 Gradient Boosting 모델이 높은 성능을 보였다. 특히 base-960h와 korean 데이터셋에서는 XGB가 가장 우수한 성능을 보였다. 모든 데이터셋에서 일관되게 우수한 성능을 보였으며, 다른 모델들과 큰 차이 없이 높은 정확도를 유지했다. Logistic Regression은 다른 모델들에 비해 상대적으로 낮은 성능을 보였으며, 특히 korean 데이터셋에서 성능 차이가 크게 나타났다.

대부분의 데이터셋에서 XGB와 Gradient Boosting 모델이 높은 성능을 보였다. 특히 base-960h와 korean 데이터셋에서는 XGB가 가장 우수한 성능을 보였다. 모든 데이터셋에서 일관되게 우수한 성능을 보였으며, 다른 모델들과 큰 차이 없이 높은 정확도를 유지했다. Logistic Regression은 다른 모델들에 비해 상대적으로 낮은 성능을 보였으며, 특히 korean 데이터셋에서 성능 차이가 크게 나타났다.

이 결과는 Gradient Boosting과 XGB 모델이 다양한 데이터셋에서 안정적으로 높은 성능을 발휘함을 보여주며, Logistic Regression은 비교적 단순한 모델로서 복잡한 데이터셋에서

성능이 떨어질 수 있음을 시사한다. SVM도 전반적으로 좋은 성능을 보였지만, 최신 앙상블 기법인 Gradient Boosting과 XGB보다는 약간 뒤처지는 경향을 보였다.